Laboratório 03 — Mineração de Métricas DORA em Repositórios Open-Source

Curso	Engenharia de Software
Disciplina	Laboratório de Experimentação de Software
Turno / Período	Noite / 6º
Professor	Danilo Maia
Laboratório	Lab03 — Mineração de métricas DORA
Grupo	João Marcelo (A) · Bernardo (B) · Miguel Diniz (C)
Repositório	`https://github.com/joaomarcelocpa/LaboratorioExperimentacao` (pasta `Laboratorio3/`)
Painel interativo das RQs	`https://joaomarcelocpa.github.io/LaboratorioExperimentacao/Laboratorio3/dashboard/#geral`
GitHub Projects	`https://github.com/users/joaomarcelocpa/projects/2`
Data de entrega	22/10/2026

1 Introdução

As métricas DORA (*deployment frequency*, *lead time for changes*, *change failure rate* e tempo de recuperação) são o padrão de mercado para medir o desempenho de entrega de software. O GitHub, porém, não registra "deploys em produção" nem "falhas em produção". Neste laboratório as métricas foram **inferidas por proxies**: release publicada como deploy, execução de CI com falha como falha. Por isso o estudo pergunta duas coisas: *qual é o valor da métrica?* e *o quanto podemos confiar nele?* (validação manual e análise de sensibilidade).

Questões de pesquisa e hipóteses (registradas antes da análise; as das RQ 03a, 04, 05 e 08b foram registradas depois da coleta, sem ajuste aos resultados, e isso é uma ameaça à validade. Texto completo em `docs/hipoteses.md`):

RQ	Pergunta	Hipótese informal
01	Qual a frequência de deploys?	Mediana entre 0,25 e 1 release/semana; poucos Elite
02	Qual o tempo entre commit e deploy?	Mediana de 1 a 7 dias; variante por commit menor que por release
03	Qual a taxa de falha das mudanças?	CFR de CI entre 10% e 25%; CFR por release abaixo de 30%
04	Qual o tempo de recuperação após falha de CI?	Mediana abaixo de 1 dia, com cauda longa e censura relevante
05	Mais deploys implica mais ou menos falhas?	Correlação fraca e negativa ($\|\rho\| < 0{,}3$)
06	Que características associam-se a melhor desempenho?	Associações fracas ($\varepsilon^2 < 0{,}06$); poucos testes significativos após Holm
07	O quanto a classificação DORA depende da definição?	30–50% mudam de classe; kappa entre 0,3 e 0,6
08 (bônus)	08a: taxa de retrabalho; 08b: evolução temporal	08a: retrabalho $\geq$ CFR (b) + 5 p.p.; 08b: maioria sem tendência

Contribuições além do enunciado (detalhadas em 3.6): cinco versões da heurística de release corretiva validadas contra a amostra-ouro, CFR por issues de bug (c), CFR de CI sem falhas *flaky*, lead time sem bots, filtro preguiçoso com semente fixa na seleção e painel web das RQs.

2 Contexto

Este é o terceiro laboratório da disciplina e muda o objeto de estudo: em vez de repositórios populares em geral (Lab01) ou katas (Lab02), são **repositórios open-source reais com GitHub Actions**, minerados para calcular as métricas do livro *Accelerate* (Forsgren, Humble & Kim, 2018) e dos relatórios *State of DevOps* do DORA. As definições operacionais são as comuns da turma: janela de 12 meses (**1/out/2025 a 30/set/2026**), apenas o *default branch*, deploy = release publicada (`draft = false`), data do commit = `author.date`, CI = runs de `push`, e classificação Elite/High/Medium/Low pelos cortes fixos do enunciado.

3 Metodologia

3.1 Principais desafios

- **Teto de 1.000 resultados da API.** A busca de candidatos foi fatiada por faixas de estrelas (65.450 candidatos). Nos runs de CI, a janela foi bisseccionada até fatias de ∼40 minutos; mesmo assim 69 intervalos (11 repositórios; `pytorch/pytorch` 24, `dust-tt/dust` 15, `twentyhq/twenty` 10, `openai/codex` 8) continuaram saturados e ficaram incompletos. Estão registrados em `fatias_saturadas.csv`.

- **Custo de cota.** Examinar 37 mil candidatos levaria dias de cota. Solução: pré-filtro por `pushed_at` e exame em ordem aleatória (seed 42) até fechar 300 aprovados (#58).
- **Volume de dados.** `commits.csv` (244 MB) e `runs.csv` (114 MB) passam do limite do GitHub e são versionados em `.gz` determinístico (#65).
- **Monorepos e tags com `/` ou `#`** quebravam o `compare` (erro 422, #56); tags passaram a ser codificadas na URL. Monorepos foram mantidos e registrados como ameaça (#63).
- **Heurística de release corretiva** não atingiu o F1 de 0,70 exigido (ver 3.2 e 4.1).

3.2 Tomadas de decisão

Decisão	**Justificativa**
Amostra aleatória simples, **não estratificada**	As primeiras 300 aprovações de uma ordem aleatória fixa são amostra uniforme dos aprovados; reprodutível pela seed
Análise sobre **299 de 300** repositórios	Um repositório não teve coleta completa
Métrica ausente fica vazia (NaN), nunca zero	Evita distorcer mediana e IQR; cada análise informa seu n
Mediana e IQR em todas as RQs	Distribuições muito assimétricas
Heurística de release corretiva **v5**	Maior F1 entre cinco versões testadas (alto recall, precisão baixa)
Tipo do projeto como fator da RQ 06, **só nos 60 da amostra-ouro**	O rótulo manual existe só para eles; resultado tem pouco poder
RQ 08b: Mann-Kendall **mensal** (12 pontos)	Com 4 trimestres o menor p possível é $\approx 0{,}08$, nenhum repositório poderia ser significativo
Desempate da conferência: maioria 2-1; 1-1-1 decidido em reunião	`docs/protocolo_desempate.md`

3.3 Etapas

Sprint	Entregas	A (João)	B (Bernardo)	C (Miguel)	Issues
S01	Pipeline para 100 repositórios, testes, CI, hipóteses	seleção, funil, metadados, CFR por issues, classificação	releases/tags/commits, frequência, lead time, corretiva	cliente HTTP/cache, runs, CFR de CI, recuperação	#37–#48
S02	300 repositórios, métricas, validação manual, metodologia	rodada final, ferramentas da amostra-ouro	monorepos, regra corretiva	`commits.csv`, dataset e dicionário	#56, #58, #61–#67
S03	Análise das RQ 01–07 e bônus, painel	RQ 01–04 e classe C1	RQ 05 e 06	RQ 07 e 08	#72–#79

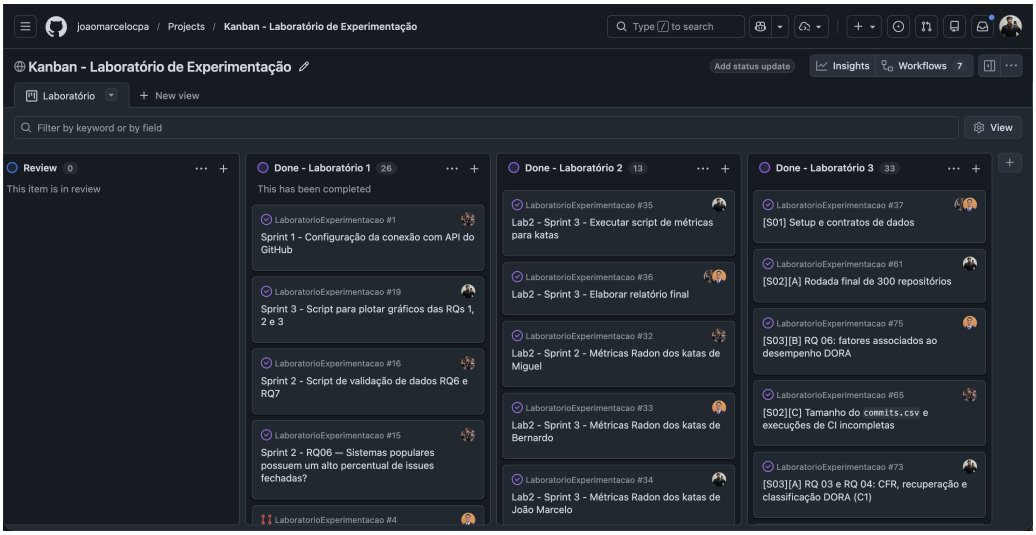


Figura 1: Quadro Kanban (GitHub Projects) ao final do laboratório.

3.4 Ferramentas

Python 3.12; `requests` (REST) e GraphQL do GitHub com cliente próprio (sem PyGithub); SQLite para cache e retomada; pandas, SciPy, statsmodels, scikit-learn e `pymannkendall` para estatística; matplotlib para os gráficos; pytest + pytest-cov (cobertura mínima de 80%) e GitHub Actions para CI; Docker e `make` para reprodução (`make run`, `make reproduce`, `make dashboard`).

3.5 Tabela de métricas

RQ	Métrica	Definição operacional	Unidade
01	Deployment frequency	releases publicadas na janela ÷ 52,1 semanas	releases/semana
02a	Lead time por release	`published_at(R)` − data do commit mais antigo de R; mediana das releases	dias
02b	Lead time por commit	`published_at(R)` − data de cada commit de R; mediana de todos	dias
03a	CFR de CI	falhas ÷ (falhas + sucessos) dos runs de push no default branch	%
03b	CFR por release	releases seguidas de corretiva em ≤ 7 dias ÷ releases avaliadas	%
04	Tempo de recuperação	fim do 1º sucesso após falha − início da 1ª falha, por workflow; mediana do repositório	horas
05	Spearman	ρ entre frequência (RQ 01) e CFR (a) e (b)	ρ
06	Kruskal-Wallis + ε^2 + Holm	métricas × fatores (quartis ou grupos)	ε^2
07	% que muda de classe, κ ponderado linear	C1, C2, C3	% / κ
08a	Taxa de retrabalho (*rework rate*)	releases corretivas ÷ releases avaliadas, sem limite de dias	%
08b	Mann-Kendall mensal	por repositório, $\alpha = 0{,}05$, Holm por métrica	direção

3.6 Inovações propostas pelo grupo

Inovação	O que foi feito	Onde aparece
Heurística corretiva v1–v5	Cinco versões comparadas à amostra-ouro (P/R/F1)	4.1, RQ 03
CFR de CI sem *flaky*	Remove falhas seguidas de sucesso no mesmo `head_sha`	RQ 03
CFR por issues de bug (c)	Terceiro proxy de falha, via labels de bug	RQ 03
Lead time sem bots	Variante que exclui commits de bots	RQ 02
Taxa de retrabalho e taxa de retrabalho em 7 dias	Bônus 08a	RQ 08
Seleção preguiçosa com seed	Reduz custo de cota sem alterar quem pode entrar	4.1
Painel web das RQs	Página estática com hipótese, veredito e gráficos	link no topo

4 Resultados

4.1 Coleta de dados

Funil de seleção (seed 42; janela 1/10/2025 a 30/9/2026):

Etapa	**Entraram**	**Saíram**
Candidatos da busca ($\geq$ 1.000 estrelas)	65.450	
Duplicatas / forks / arquivados	65.450	26 / 0 / 5.361
Sem push na janela	60.063	22.710
Elegíveis	**37.353**	
Não examinados (amostra fechou antes)	37.353	35.999
Examinados	1.354	
Não usa GitHub Actions	1.354	240
Menos de 5 releases	1.114	711
Menos de 50 runs válidos	403	103
Aprovados (22% dos examinados)	**300**	

Dataset: **299 repositórios analisados**, 16.536 releases, 13.745 episódios de falha de CI. Ausências: tempo de recuperação em 26 repositórios (sem falha de CI) e CFR por issues em 77.

Validação manual (amostra-ouro: 60 repositórios, 300 releases, 3 avaliadores independentes):

Dimensão	**κ de Fleiss**	**Leitura**
Tipo do projeto	0,885	quase perfeita
Entregas reais	0,236	razoável (95% unânimes; κ baixo pela pouca variação nas respostas)
Release corretiva	0,661	substancial

Heurística de release corretiva (releases decidíveis, $n = 240$):

Versão	**F1**	**Precisão**	**Recall**
v1	0,604	0,443	0,949
v2	0,535	0,519	0,551
v3	0,605	0,487	0,796
v4	0,607	0,442	0,969
v5 (adotada)	**0,638**	**0,475**	**0,969**

Nenhuma versão chegou ao F1 de 0,70. A v5 acerta quase todas as corretivas, mas

marca muitas releases normais como corretivas; **o CFR (b) deve ser lido como limite superior**.

4.2 Resultados por RQ

Todas as figuras estão em `analise/saida/figuras/` e as tabelas em `analise/saida/tabelas/` (regeneráveis com `make reproduce`).

RQ 01 — Frequência de deploy

	n	Mediana	IQR
Releases/semana	299	**0,33**	0,17 – 0,76

Faixa DORA	Repositórios	%
Elite ($\geq$ 7/sem)	3	1,0%
High (1–7/sem)	56	18,7%
Medium (1/mês–1/sem)	121	40,5%
Low ($<$ 1/mês)	119	39,8%

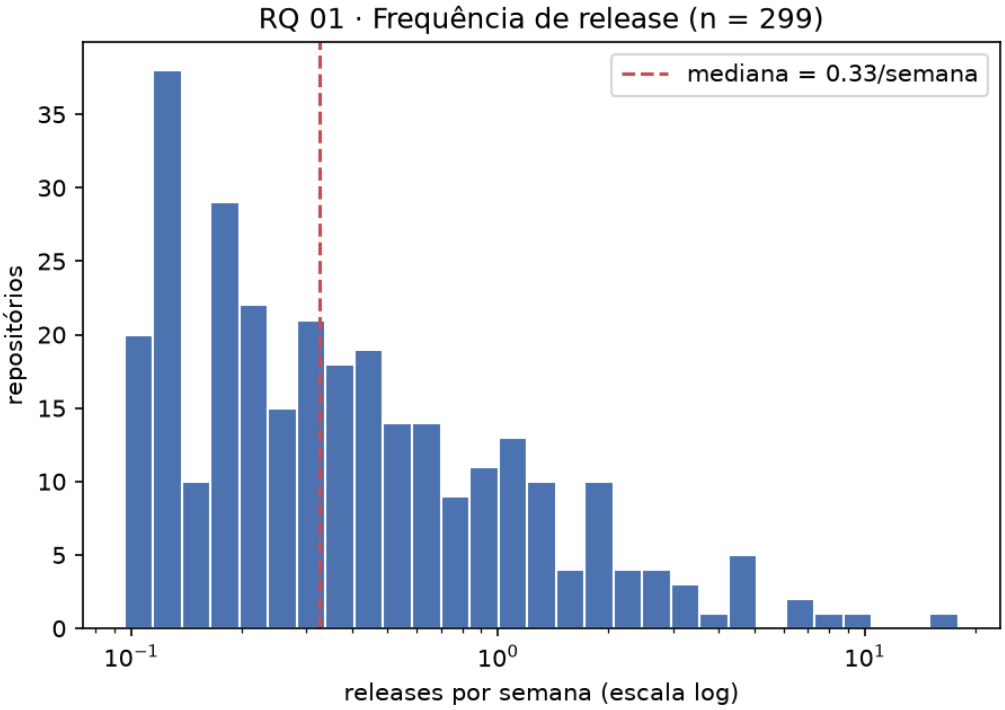


Figura 2: RQ 01 — Distribuição da frequência de deploy (releases/semana).

Hipótese confirmada. Mediana dentro de 0,25–1, só 3 Elite, média (0,79) acima do dobro da mediana. Contar tags ou pré-releases sobe a mediana (0,44 e 0,38), sem mudar de faixa.

RQ 02 — Lead time

Variante	Mediana (dias)	IQR (dias)
(a) por release	**8,3**	1,8 – 29,3
(b) por commit	**8,1**	1,9 – 25,6

(a) é maior que (b) em 66% dos repositórios; só 27,8% estão entre 1 e 7 dias. Sem commits de bots, a mediana de (b) cai para 7,7 dias.

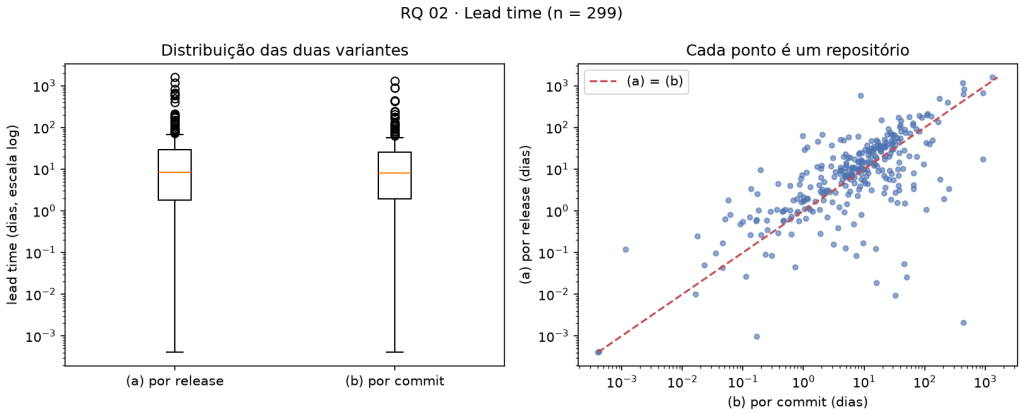


Figura 3: RQ 02 — Lead time por release e por commit.

Hipótese parcial. A direção (b < a) se confirma, mas a diferença na mediana é de só 2,4%. O nível erra: a mediana está na faixa Medium (acima de 7 dias), não High.

RQ 03 — Taxa de falha (CFR)

Variante	n	Mediana	IQR	Faixa DORA
(a) CI	299	**5,2%**	1,9% – 10,7%	Elite
(b) release corretiva	299	**37,5%**	16,7% – 66,0%	Medium
(c) issues de bug (extra)	222	37,4%	9,3% – 77,8%	

Falhas *flaky* são 3,5% das falhas (mediana); removê-las muda a mediana do CFR (a) de 6,1% para 5,5% (−0,7 p.p.).

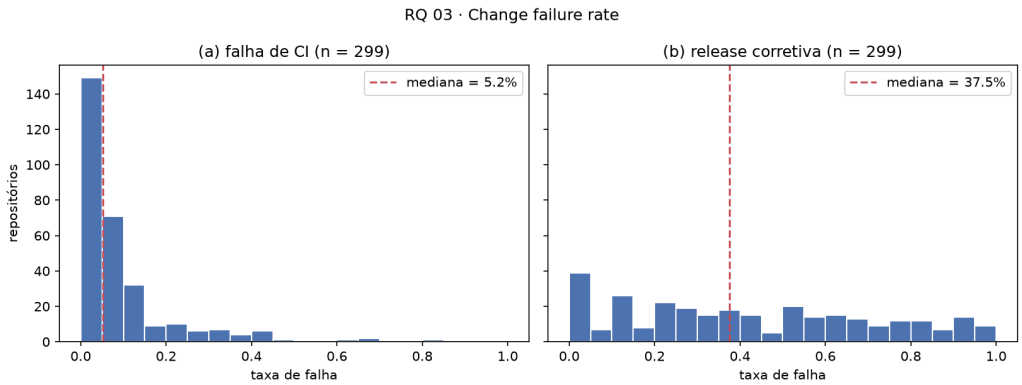


Figura 4: RQ 03 — Histogramas do CFR por variante.

Hipótese refutada. 73,6% dos repositórios têm CFR (a) abaixo de 10% (previsto: 10–25%) e só 38,8% têm CFR (b) abaixo de 30% (previsto: maioria). A expectativa de queda perceptível sem *flaky* não se confirmou. A diferença entre (a) e (b) é de sete vezes: o resultado depende do proxy, e o (b) tem a precisão limitada vista em 4.1.

RQ 04 — Tempo de recuperação

	n	Mediana	IQR
Recuperação (h)	273	**2,6**	0,6 – 13,2

51% dos repositórios estão na faixa High (1 h a 1 dia); 44 têm mediana acima de 1 dia e 9 acima de 1 semana. Apenas 76 dos 13.745 episódios (0,6%) foram censurados, e 3 são só de *flaky*.

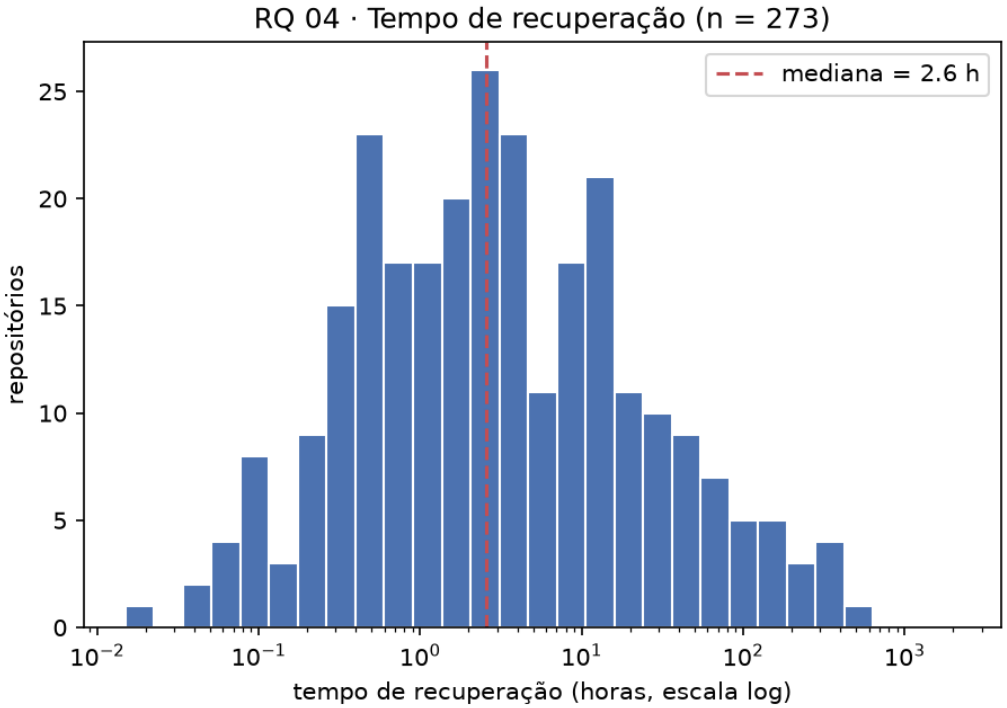
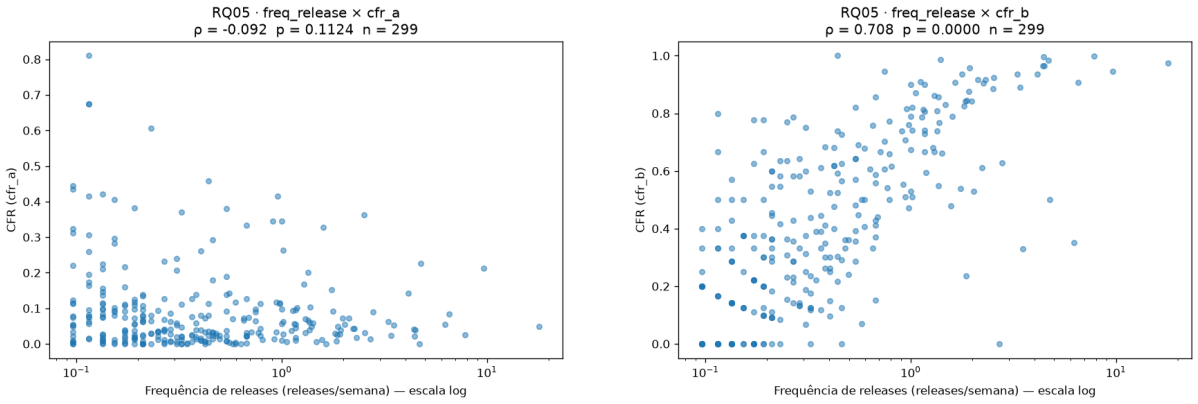


Figura 5: RQ 04 — Distribuição do tempo de recuperação (horas).

Hipótese parcial. Mediana abaixo de 1 dia e cauda longa se confirmam. A censura relevante e o aumento da mediana sem *flaky* (2,6 h para 2,5 h) não se confirmam.

RQ 05 — Frequência × CFR

CFR	ρ de Spearman	p	n
(a) CI	−0,092	0,11	299
(b) release	**+0,708**	< 0,001	299



(a) CFR (a) — CI **(b)** CFR (b) — release corretiva

Figura 6: RQ 05 — Dispersão entre frequência de deploy e CFR.

Hipótese parcial. Com o CFR (a), a relação é fraca e negativa, mas não significativa: não há sinal de *trade-off*, em linha com o DORA. Com o CFR (b) o sinal inverte e é forte. Provável explicação (não testada): é parcialmente mecânico, porque quem publica mais tem mais chance de ter outra release em até 7 dias, e a heurística lê isso como correção. Correlação não implica causalidade.

RQ 06 — Fatores associados ao desempenho

Kruskal-Wallis, 5 fatores × 5 métricas = 25 testes, correção de Holm. **7 dos 25 são significativos**; 13 têm $\varepsilon^2 < 0{,}06$.

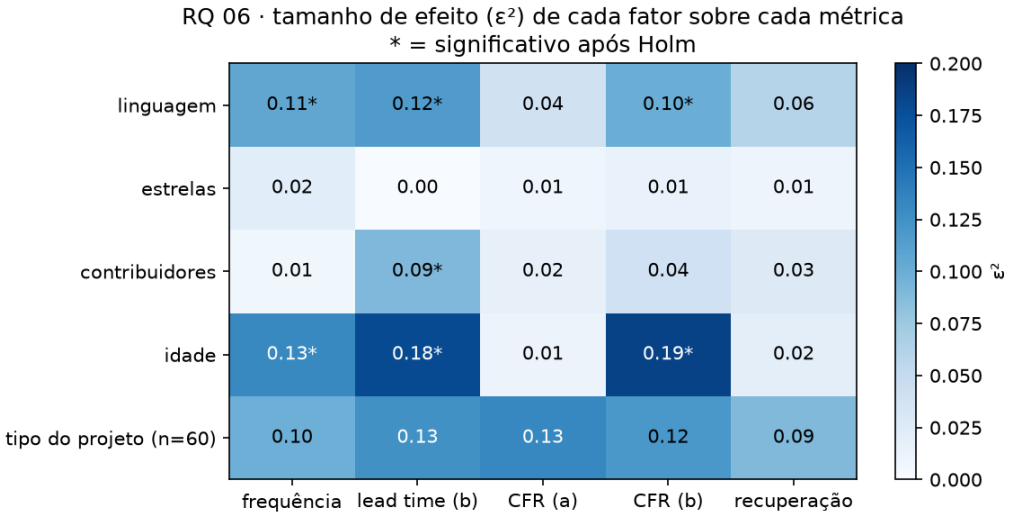


Figura 7: RQ 06 — Tamanhos de efeito (ε^2) por fator e métrica.

Fator	Resultado significativo após Holm
Idade	frequência (ε^2 0,13), lead time (0,18), CFR (b) (0,19)
Linguagem	frequência (0,11), lead time (0,12), CFR (b) (0,10)
Contribuidores	só lead time (0,09)
Estrelas	nenhum
Tipo do projeto ($n = 60$)	nenhum

Mediana de frequência por quartil de idade (Q1 mais novo → Q4 mais velho): 0,90 → 0,31 → 0,27 → 0,21 releases/semana; lead time por commit: 1,9 → 8,1 → 13,2 → 21,3 dias; CFR (b): 70% → 36% → 27% → 33%. Por linguagem, TypeScript tem 0,58/semana e C++ 0,16.

Hipótese parcial. Confirmado: estrelas sem efeito e linguagem acima de C++. Refutado: a idade tem o **maior** efeito (esperado pequeno) e contribuidores não afetam frequência. Automação de release e Conventional Commits foram coletados (`repos.csv`) mas **não entraram nos testes**. Os testes só detectam diferença entre grupos; a direção vem das medianas.

RQ 07 — Sensibilidade da classificação DORA

Combinação	Deploy	Lead time	CFR
C1 (referência)	release	(a)	(a)
C2	release + pré-release	(b)	(b)
C3	tag	(b)	(a)

Par	Mudaram de classe	κ ponderado	Leitura
C1 × C2	137 (45,8%)	0,316	razoável
C1 × C3	82 (27,4%)	0,656	substancial
C2 × C3	127 (42,5%)	0,405	moderada

165 repositórios (55,2%) mudam de classe em pelo menos um par. Percentual de repositórios cuja nota muda ao trocar a definição: **CFR 78,6%**, lead time 47,8%, unidade de deploy 7,4% a 18,7%.

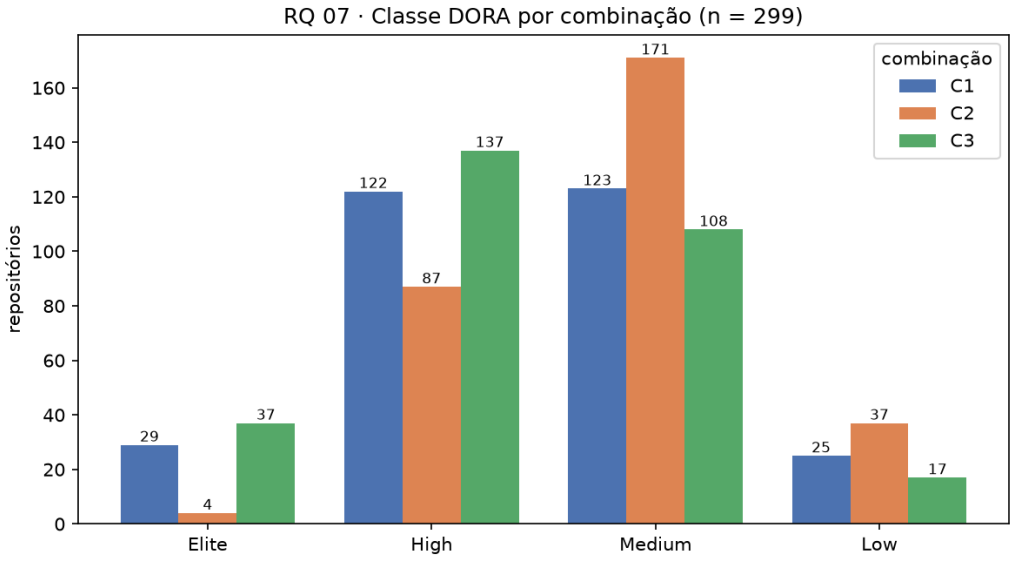


Figura 8: RQ 07 — Classes DORA por combinação de definições.

Hipótese parcial. Kappas ficam na faixa prevista e nenhum é quase perfeito, mas a mudança total (55%) passa do previsto, e o fator dominante é o **CFR**, não lead time nem unidade de deploy. Robustez das demais RQs: frequência e lead time sobrevivem na mediana (ambos Medium); CFR, o sinal da RQ 05 e a significância da RQ 06 para CFR **dependem da definição**. A recuperação não foi variada (as três combinações usam a mesma). A C3 não é uma definição "por tag" completa: o lead time (b) continua medido sobre commits entre releases.

RQ 08 (bônus) — Taxa de retrabalho e evolução temporal

08a — Taxa de retrabalho (*rework rate*). Mediana de 100% contra 37,5% do CFR (b), diferença de 62,5 p.p.; 51,5% dos repositórios têm todas as releases avaliadas como corretivas. A hipótese (≥ 5 p.p.) é confirmada, mas a métrica sem limite de dias **satura e deixa de discriminar**; com limite de 7 dias ela coincide com o CFR (b). Análise exploratória, calculada para o painel (`dashboard/`).

08b — Evolução temporal. Mann-Kendall mensal por repositório ($\alpha = 0{,}05$):

Métrica	Testados	Melhora	Piora	Sem tendência	Com Holm (melhora / piora)
CFR de CI (a)	211	12 (5,7%)	11 (5,2%)	188 (89,1%)	0 / 1
Recuperação	94	4 (4,3%)	2 (2,1%)	88 (93,6%)	0 / 0

A série mensal da mediana entre repositórios também não tem tendência ($p = 0{,}84$ no CFR; $p = 0{,}19$ na recuperação). Frequência por trimestre, descritivo: 0,15 → 0,31 → 0,31 → 0,38 releases/semana.

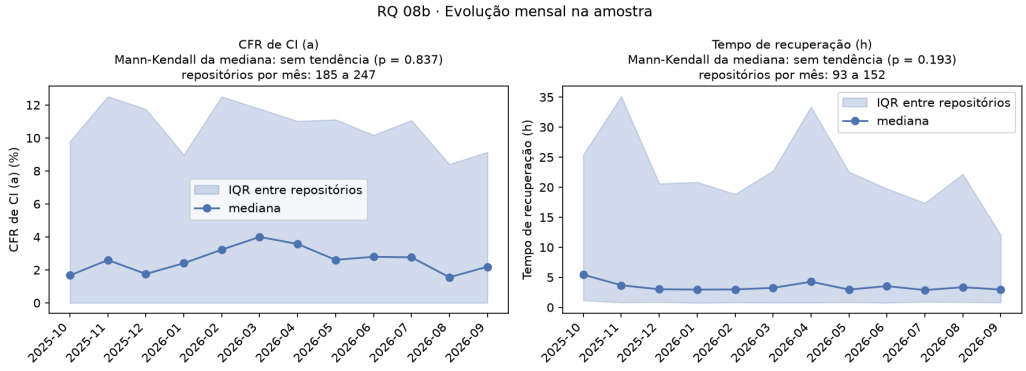


Figura 9: RQ 08b — Série mensal de exemplo (amostra de repositórios).

Hipótese parcial. "Maioria sem tendência" confirmada. "Mais melhora do que piora" não se sustenta: 12 contra 11 no CFR, e com Holm sobra só uma piora. A recuperação cobre apenas 94 repositórios (os de CI mais instável), e com 12 pontos por série "sem tendência" significa "não detectável".

4.3 Discussão

RQ	Hipótese	Veredito	O que surpreendeu
01	0,25–1 release/semana, poucos Elite	**Confirmada**	Nada: 40% ficam em Low
02	1–7 dias; (b) < (a)	Parcial	Mediana de 8 dias; as variantes quase não diferem
03	CFR (a) 10–25%; (b) < 30%	**Refutada**	CI muito estável (5%) e (b) muito alto (38%)
04	< 1 dia, cauda longa, censura relevante	Parcial	Censura quase nula (0,6%)
05	ρ fraco e negativo	Parcial	$\rho = +0{,}71$ com o CFR (b)
06	efeitos fracos	Parcial	Idade é o fator mais forte (ε^2 até 0,19)
07	30–50% mudam; κ 0,3–0,6	Parcial	Quem pesa é o CFR, não lead time
08	08a retrabalho > CFR (b); 08b sem tendência	Parcial	O retrabalho satura em 100%

Leitura geral. O desempenho típico da amostra é *Medium/High*: releases a cada três semanas, lead time de ∼8 dias, CI que quebra pouco (5%) e se recupera em poucas horas. O que mais pesa é a **definição de falha**: CFR (a) e (b) diferem sete vezes, mudam o sinal da correlação com a frequência e reclassificam 55% dos repositórios. Recomenda-se reportar sempre os dois lado a lado. A idade do repositório é o fator mais associado ao desempenho: repositórios novos publicam mais e entregam mais rápido, mas têm mais releases corretivas, o que é compatível com projetos jovens em iteração rápida.

Ameaças à validade.

- *Construto:* release ≠ deploy (subestima serviços com deploy contínuo e superestima bibliotecas com release automática); CFR de CI mede falha de pipeline, não de produção; `author.date` sofre com rebase e squash; heurística corretiva com F1 de 0,64 e rótulos de Bernardo divergentes dos de João e Miguel (171 contra 112 e 111 corretivas); labels de bug fixos deixam 77 repositórios sem CFR (c).
- *Interna:* 69 intervalos de CI incompletos em 11 repositórios afetam CFR (a), recuperação e série mensal; monorepos mantidos; hipóteses das RQ 03a, 04, 05 e 08b registradas depois da coleta; o efeito da idade pode estar confundido com a política de releases.
- *Externa:* só repositórios com ≥ 1.000 estrelas, com Actions e ≥ 5 releases na janela (22% dos examinados); amostra não estratificada (7 repositórios acima de 50 mil estrelas); popularidade medida na data da coleta.
- *Conclusão:* 25 testes na RQ 06 (corrigidos por Holm); tipo do projeto testado só em 60 repositórios; 12 pontos por série na RQ 08b; cortes DORA fixos e arbitrários na RQ 07.

5 Conclusão

Para os 299 repositórios populares com CI/CD analisados, a entrega típica é de uma release a cada três semanas (0,33/semana), com lead time de ∼8 dias, CFR de CI de 5%,

CFR por release de 38% e recuperação de 2,6 horas. A classe DORA de referência (C1) é Medium (41%) ou High (41%) para a maioria, com 10% Elite e 8% Low.

Sobre velocidade e estabilidade: pelo CI não há trade-off detectável ($\rho = -0{,}09$), mas pela release corretiva a relação é fortemente positiva ($\rho = +0{,}71$), provavelmente por artefato da medida. A conclusão depende do proxy, e a análise de sensibilidade mostra que o CFR é a escolha que mais reclassifica repositórios (55% mudam em algum par). Nas 8 RQs, 1 hipótese foi confirmada, 6 parcialmente e 1 refutada. Idade e linguagem são os fatores mais associados ao desempenho, e as métricas de CI não mostram tendência na janela.

Limitações: proxies de deploy e falha; heurística corretiva com F1 de 0,64 (abaixo do 0,70 exigido); CI incompleto em 11 repositórios; amostra limitada a repositórios populares.

Com mais tempo: melhorar a precisão da heurística corretiva (por exemplo, rotulando mais releases com critério comum), incluir automação de release e Conventional Commits nos testes da RQ 06, medir um lead time por tag completo e repetir a RQ 06 sob C2 e C3.

6 Referências

- Forsgren, N.; Humble, J.; Kim, G. *Accelerate: The Science of Lean Software and DevOps*. IT Revolution, 2018.
- DORA. *Accelerate State of DevOps* e guia das métricas: `https://dora.dev/guides/dora-metrics-four-keys/`
- Wohlin, C. et al. *Experimentation in Software Engineering*. Springer, 2012.
- Romano, J. et al. *Appropriate statistics for ordinal level data*. 2006.
- Landis, J. R.; Koch, G. G. *The measurement of observer agreement for categorical data*. Biometrics, 1977.